




MISTURE FINITE DI MVPLN PER MATRICI A TRE VIE NELL'RNA-SEQ


Anjali Silva, Xiaoke Qin, Steven J Rothstein, Paul D McNicholas, Sanjeena Subedi, Finite mixtures of matrix variate Poisson-log normal distributions for three-way count data, *Bioinformatics*, Volume 39, Issue 5, May 2023, btad167, <https://doi.org/10.1093/bioinformatics/btad167>



RNA-SEQ


Cos'è?

L'**RNA sequencing**, anche detto RNA-seq, è una **tecnologia** avanzata di **sequenziamento** utilizzata per analizzare l'espressione genica e il contenuto di RNA in un campione biologico. Questa tecnica consente di identificare e quantificare i trascritti di RNA, fornendo una visione dettagliata del **trascrittoma**, ovvero l'insieme di tutte le molecole di RNA espresse in un dato momento in una cellula o tessuto.




Come funziona l'RNA-seq?

1. **Preparazione del campione:** il DNA viene estratto, frammentato e modificato con adattatori specifici che facilitano il successivo processo di sequenziamento.
2. **Amplificazione dei frammenti:** i frammenti di DNA vengono moltiplicati per ottenere una quantità sufficiente di materiale genetico, migliorando la sensibilità e l'affidabilità del sequenziamento.
3. **Sequenziamento:** i frammenti di DNA vengono letti in parallelo tramite diverse tecnologie per generare le sequenze nucleotidiche complete.



Come si procede per analizzare i dati?

Si definiscono **reads** le sequenze che identificano l'ordine in cui si susseguono le basi nei frammenti di DNA. Il totale delle **reads** allineate su una regione d'interesse del genoma (un gene o un trascritto) è detto **count** e può essere inteso come una misura del livello di espressione di quella regione. In esperimenti comparativi, le misurazioni coinvolte in un esperimento di RNA-seq sono fatte su più campioni in modo da avere più variabilità biologica.



Le espressioni di ciascun campione sono riassunte in un vettore di **counts**, mentre le espressioni di tutti i campioni vanno a formare una matrice.

Per loro stessa definizione, dal punto di vista statistico i **counts** rappresentano una somma di eventi aleatori indipendenti (la mappatura di ogni **read** sui geni). Possono quindi essere descritti da una **variabile aleatoria** che segue una determinata distribuzione statistica.



CLASSIFICAZIONE BASATA SU MODELLO

CLASSIFICAZIONE BASATA SU MODELLO

I metodi di classificazione basati su modello descrivono i dati come generati da un processo aleatorio. Tale processo può seguire una legge di probabilità corrispondente ad una **mistura di distribuzioni**.

L'inferenza sui parametri della distribuzione permette di:

- ❖ **Approssimare la distribuzione** dei dati, eventualmente valutandone l'adattamento
- ❖ **Assegnare le unità ai cluster** con probabilità maggiore, tramite la regola *Maximum A Posteriori*, basata sulla Legge di Bayes

VANTAGGI

VANTAGGI

TALE APPROCCIO OFFRE NUMEROSI VANTAGGI, TRA CUI:

Minore arbitrarietà
nella definizione e nel numero dei
cluster rispetto ai criteri euristici


Permette di **confrontare modelli**
diversi e di fare **inferenza** sui
parametri stimati

La procedura è
invariante per scala

MATRICI A TRE VIE

Una matrice a tre vie è rappresentata da una matrice casuale $\mathbf{Y}_n$, che contiene tre dimensioni principali, dette modalità:

Tempi	→	Righe:	$i \in \{1, \dots, r\}$
Variabili	→	Colonne:	$k \in \{1, \dots, p\}$
Geni	→	Strati:	$n \in \{1, \dots, N\}$



Utilizziamo un **modello mistura finita** (FFM) per effettuare un raggruppamento **delle N unità in G gruppi**, sfruttando le informazioni provenienti dalle altre due modalità (tempi e variabili).

ASSUNZIONI DEL MODELLO MISTURA FINITA

Sia $\{Y_1, \dots, Y_n, \dots, Y_N\}$ un campione casuale di unità - ognuna rappresentata da una matrice a tre vie - provenienti da una popolazione P suddivisa in G sottopopolazioni, non sovrapposte e non osservate:

$$P = \{P_1, \dots, P_g, \dots, P_G\}$$

Le sottopopolazioni sono caratterizzate da **bassa varianza within** e **alta varianza between**

Si assume che:

- ❖ $Y_1, \dots, Y_N$ siano osservazioni indipendenti e identicamente distribuite condizionatamente al cluster di appartenenza

ASSUNZIONI DEL MODELLO MISTURA FINITA

Per ciascuna sottopopolazione P_g definiamo la **probabilità di appartenenza**

$$\pi_g = \Pr(Y_n \in P_g) \quad : \quad \begin{cases} 0 \leq \pi_g \leq 1 & g = 1, \dots, G \\ \sum_{g=1}^G \pi_g = 1 \end{cases}$$

Si assume che:

- ❖ Ogni osservazione proviene da una mistura di G cluster, proporzionalmente alle probabilità $\boldsymbol{\pi} = (\pi_1, \dots, \pi_G)$

Definiamo inoltre:

La variabile strumentale Z_{ng}

La numerosità del g -esimo cluster


$$Z_{ng} = \begin{cases} 1, & \text{se } Y_n \in P_g \\ 0, & \text{se } Y_n \notin P_g \end{cases}$$

$$n_g = \sum_{n=1}^N Z_{ng}$$

La densità della g-esima componente della mistura è:

$$f(\mathbf{Y}_n | \pi_1, \dots, \pi_G, \boldsymbol{\vartheta}_1, \dots, \boldsymbol{\vartheta}_G) = \sum_{g=1}^G \pi_g f^{(r \times p)}(\mathbf{Y}_n | \boldsymbol{\vartheta}_g)$$

Ma qual è la distribuzione più adeguata per dati RNA-seq?



DALLA MPLN ALLA MVPLN

La distribuzione **MPLN** (Multivariate Poisson-log Normal) è stata proposta⁽¹⁾ per modellare dati di conteggio **sovradispersi** e **multivariati**, organizzati in matrici a due dimensioni

Per l' n -esimo gene e il c -esimo campione la distribuzione è definita da

$$Y_{nc} | \theta_{nc} \sim \text{Poisson}(\exp(\theta_{nc} + \log s_c)) \quad n \in \{1, \dots, N\}, c \in \{1, \dots, rp\}$$

$$(\theta_{n1}, \dots, \theta_{nrp})' \sim N_{rp}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

s_c : numero delle **reads** che sono state mappate sul campione c

Un'estensione naturale della MPLN per dati RNA-seq a **tre vie** è la **MVPLN** (Matrix Variate Poisson-log Normal) proposta dagli stessi autori⁽²⁾ come modello mistura di distribuzioni matriciali **Poisson-LogNormali**. La MVPLN è applicabile quando:

- ❖ sono disponibili misurazioni in **condizioni** e **tempi** diversi
- ❖ è necessario tener conto delle **correlazioni** sia tra variabili che tra tempi

(1) Silva A, Rothstein SJ, McNicholas PD et al. A multivariate Poisson-log normal mixture model for clustering transcriptome sequencing data. BMCBioinformatics 2019

(2) Silva A, Xiaoke Q, Rothstein SJ, McNicholas PD et al. Finite mixtures of matrix variate Poisson-log normal distributions for three-way count. Bioinformatics 2023

LA DISTRIBUZIONE MVPLN

La **densità di probabilità** della MVPNL per l'n-esimo gene rispetto a $\boldsymbol{\vartheta} = (\mathbf{M}, \boldsymbol{\Phi}, \boldsymbol{\Omega})$ è definita come:

$$f(\mathbf{Y}_n, \mathbf{s} | \boldsymbol{\vartheta}) = \int_{\mathbb{R}} \left\{ \prod_{c=1}^{rp} f(\text{vec}(\mathbf{Y}_n^T)_c | \text{vec}(\boldsymbol{\theta}_n^T)_c, \text{vec}(\mathbf{s})_c) \right\} g^{(r \times p)}(\boldsymbol{\theta}_n | \boldsymbol{\vartheta}) d\text{vec}(\boldsymbol{\theta}_n^T)$$

Dati osservati

$$\mathbf{Y}_n^{[r \times p]}; n = 1, \dots, N$$

Matrici aleatorie IID, dove $Y_{nik} | \theta_{nik} \sim \text{Poisson}(\exp(\theta_{nik}))$

Altre definizioni

$\text{vec}(\mathbf{Y}_n^T); \text{vec}(\mathbf{s}); \text{vec}(\boldsymbol{\theta}_n^T)$ vettorizzazioni delle matrici

$f(\cdot)$ funzione di massa di probabilità della Poisson

$g^{(r \times p)}(\cdot)$ funzione di densità di probabilità della distribuzione normale matriciale

Parametri incogniti

$$\boldsymbol{\theta}_n^{[r \times p]} \sim N(\mathbf{M}, \boldsymbol{\Phi}, \boldsymbol{\Omega})$$

$\mathbf{M}^{[r \times p]}$ matrice delle medie

$\boldsymbol{\Phi}^{[r \times r]}$ matrice di covarianza dei tempi

$\boldsymbol{\Omega}^{[p \times p]}$ matrice di covarianza delle condizioni

MISTURA FINITE DI DISTRIBUZIONI MVPLN

Sia $\mathbf{Y}_n$ matrice aleatoria proveniente da una popolazione composta da G sottopopolazioni, tale per cui:

- ❖ ogni sottopopolazione segue una distribuzione MVPLN di parametro $\boldsymbol{\vartheta}_g = (\mathbf{M}_g, \boldsymbol{\Phi}_g, \boldsymbol{\Omega}_g)$
- ❖ le sottopopolazioni hanno proporzioni $\boldsymbol{\pi} = (\pi_1, \dots, \pi_G)$

➡ la densità della mistura di G distribuzioni MVPLN è:

$$f(\mathbf{Y}_n | \boldsymbol{\pi}, \boldsymbol{\vartheta}_1, \dots, \boldsymbol{\vartheta}_G) = \sum_{g=1}^G \pi_g f_Y(\mathbf{Y}_n | \boldsymbol{\vartheta}_g)$$

$$f_Y(\mathbf{Y}_n | \boldsymbol{\vartheta}_g) = \int \prod_{c=1}^{rp} \int_{\mathbb{R}} f_g \left(\text{vec}(\mathbf{Y}_n^T)_c | \text{vec}(\boldsymbol{\theta}_{ng}^T)_c, \text{vec}(\mathbf{s})_c \right) g_g^{(r \times p)}(\boldsymbol{\theta}_{ng} | \boldsymbol{\vartheta}_g) d\text{vec}(\boldsymbol{\theta}_{ng}^T)$$

Un vantaggio delle mistura MVPLN è la riduzione del numero di parametri da stimare

PARAMETRI LIBERI NELLA MISTURA MPLN

$$\underbrace{G - 1}_{\pi_1, \dots, \pi_G} + \underbrace{G rp}_{\mu_g} + \underbrace{G \frac{rp(rp + 1)}{2}}_{\Sigma_g}$$

PARAMETRI LIBERI NELLA MISTURA MVPLN

$$\underbrace{G - 1}_{\pi_1, \dots, \pi_G} + \underbrace{G rp}_{M_g} + \underbrace{G \frac{r(r + 1)}{2}}_{\Phi_g} + \underbrace{G \frac{p(p + 1)}{2}}_{\Omega_g}$$



STIMA DEI PARAMETRI

Proposte di **tre framework**
per la stima dei parametri
nei **modelli MVPLN**

STIMA DEI PARAMETRI

- ❖ CATENA DI MARKOV CON METODO MONTECARLO (**MCMC**)
- ❖ VARIATIONAL GAUSSIAN APPROXIMATION (**VGA**)
- ❖ APPROCCIO IBRIDO

❖ CATENA DI MARKOV CON METODO MONTECARLO

Si sfrutta l'algoritmo EM per **stimare** i parametri e assegnare i dati ai **cluster**. Alla t -esima iterazione il valore atteso di θ_{ng} e Z_{ng} , condizionato i dati aggiornati e ai parametri correnti, viene calcolato come segue:

$$\mathbb{E}(\theta_{ng} | Y_n) \simeq \frac{1}{W} \sum_{f=1}^W \theta_{ng}^{(f)} \simeq \theta_{ng}^{(t)}$$
$$\mathbb{E}(Z_{ng} | Y_n, \theta_{ng}, s) = \frac{q_{ng}}{\sum_{h=1}^G q_{nh}} := z_{ng}^{(t)}$$

- ❖ W rappresenta il numero di iterazioni necessarie a stimare i parametri
- ❖ $\theta_{ng}^{(f)}$ è simulato tramite il software R (pacchetto Rstan) per le iterazioni $f = 1, \dots, W$
- ❖ $q_{ng} = \pi_g^{(t)} \left\{ \prod_{c=1}^{rp} f_g(\text{vec}(\mathbf{Y}_n^T)_c | \text{vec}(\theta_{ng}^T)_c, \text{vec}(s)_c) \right\} \times g_g^{(r \times p)} \left(\theta_{ng}^{(t)} | \mathbf{M}_g^{(t)}, \Phi_g^{(t)}, \Omega_g^{(t)} \right)$

1. E-STEP

Calcoliamo la funzione obiettivo $Q(\boldsymbol{\theta})$ con $\boldsymbol{\theta} = (\pi_1, \dots, \pi_G, \mathbf{M}_1, \dots, \mathbf{M}_G, \boldsymbol{\Phi}_1, \dots, \boldsymbol{\Phi}_G, \boldsymbol{\Omega}_1, \dots, \boldsymbol{\Omega}_G)$ come il **valore atteso** della **logverosimiglianza completa**:

$$\begin{aligned}
 Q(\boldsymbol{\theta}) &= \mathbb{E}\{l_c(\boldsymbol{\theta})\} \\
 &\simeq C - \frac{p}{2} \sum_{g=1}^G n_g \log |\boldsymbol{\Phi}_g| - \frac{r}{2} \sum_{g=1}^G n_g \log |\boldsymbol{\Omega}_g| - \\
 &\quad \frac{1}{2} \sum_{n=1}^N \sum_{g=1}^G z_{ng}^{(t)} \mathbb{E} \left[\text{tr} \left(\boldsymbol{\Phi}_g^{-1} (\boldsymbol{\theta}_{ng} - \mathbf{M}_g) \boldsymbol{\Omega}_g^{-1} (\boldsymbol{\theta}_{ng} - \mathbf{M}_g)^T \right) | \boldsymbol{\theta}_{ng}^{(t)}, z_{ng}^{(t)} = 1 \right]
 \end{aligned}$$

con $n_g^{(t)} = \sum_{n=1}^N z_{ng}^{(t)}$

2. M-STEP

L'aggiornamento dei parametri avviene nel seguente modo:

$$\begin{aligned}
 \diamond \pi_g^{(t+1)} &= \frac{n_g^{(t)}}{N} \\
 \diamond \mathbf{M}_g^{(t+1)} &= \frac{\sum_{n=1}^N z_{ng}^{(t)} \mathbb{E}(\boldsymbol{\theta}_{ng})}{n_g} \\
 \diamond \boldsymbol{\Phi}_g^{(t+1)} &= \frac{\sum_{n=1}^N z_{ng}^{(t)} \mathbb{E}(\left(\boldsymbol{\theta}_{ng} - \mathbf{M}_g^{(t+1)}\right) \left(\boldsymbol{\Omega}_g^{(t)}\right)^{-1} \left(\boldsymbol{\theta}_{ng} - \mathbf{M}_g^{(t+1)}\right)^T)}{p n_g} \\
 \diamond \boldsymbol{\Omega}_g^{(t+1)} &= \frac{\sum_{n=1}^N z_{ng}^{(t)} \mathbb{E}(\left(\boldsymbol{\theta}_{ng} - \mathbf{M}_g^{(t+1)}\right) \left(\boldsymbol{\Phi}_g^{(t+1)}\right)^{-1} \left(\boldsymbol{\theta}_{ng} - \mathbf{M}_g^{(t+1)}\right)^T)}{r n_g}
 \end{aligned}$$

❖ VARIATIONAL GAUSSIAN APPROXIMATION

La **vga** è una tecnica in cui si utilizza una densità di probabilità approssimativa, più semplice da trattare computazionalmente, rispetto alla densità vera. L'obiettivo è minimizzare la divergenza di **Kullback-Leibler** (KL) tra la densità vera e quella approssimata.

$q(\boldsymbol{\theta})$	densità approssimativa, assunta gaussiana
$\log f_Y(\mathbf{Y}) = F(q, \mathbf{Y}) + D_{KL}(q f_Y)$	Log-verosimiglianza dei dati osservati
$D_{KL}(q f_Y) = \int q(\boldsymbol{\theta}) \log \frac{q(\boldsymbol{\theta})}{f(\boldsymbol{\theta} \mathbf{Y})} d\boldsymbol{\theta}$	distanza KL
$F(\mathbf{Y}, q) \triangleq \int [\log f(\mathbf{Y}, \boldsymbol{\theta}) - \log q(\boldsymbol{\theta})] q(\boldsymbol{\theta}) d\boldsymbol{\theta}$	funzione obiettivo, conosciuta come ELBO (Evidence Lower Bownd)

→ **OBIETTIVO**: massimizzarla

La funzione di log-verosimiglianza completa è:

$$\begin{aligned} l_c(\Theta) &= \sum_{g=1}^G \sum_{n=1}^N z_{ng} \log \pi_g + \sum_{g=1}^G \sum_{n=1}^N z_{ng} \log f(Y_n | \mathbf{M}_g, \Phi_g, \Omega_g) \\ &= \sum_{g=1}^G \sum_{n=1}^N z_{ng} \log \pi_g + \sum_{g=1}^G \sum_{n=1}^N z_{ng} [F(\mathbf{Y}_n, q_{ng}) + D_{KL}(q_{ng} || f_{ng})] \end{aligned}$$

Per ogni osservare $\mathbf{y}_n$ dobbiamo massimizzare l'ELBO

$$\begin{aligned} F(q_{ng}, \mathbf{Y}_n) &= - \left[\sum_{i=1}^r \sum_{j=1}^p \exp \left\{ (\xi_{ng})_{ij} + \frac{1}{2} (\Delta_{ng})_{ii} (\Omega_{ng})_{jj} + \log s_{ij} \right\} \right] \\ &\quad + [\text{vec}(\xi_{ng}^T) + \log \text{vec}(s)]^T \text{vec}(\mathbf{Y}_n^T) \\ &\quad - \left[\sum_{c=1}^{rp} \log(\text{vec}(\mathbf{Y}_n^T)_c!) \right] - \frac{p}{2} \log |\Phi_g| - \frac{r}{2} \log |\Omega_g| \\ &\quad - \frac{1}{2} \left(\text{vec}(\xi_{ng}^T) - \text{vec}(\mathbf{M}_g^T) \right)^T \Phi_g^{-1} \otimes \Omega_g^{-1} \left(\text{vec}(\xi_{ng}^T) - \text{vec}(\mathbf{M}_g^T) \right) \\ &\quad + \text{tr} \{ \Phi_g^{-1} \Delta_{ng} \} \text{tr} \{ \Omega_g^{-1} \kappa_{ng} \} + \frac{p}{2} \log |\Delta_{ng}| + \frac{r}{2} \log |\kappa_{ng}| + \frac{rp}{2} \end{aligned}$$

1. E-STEP

$$\mathbb{E}(Z_{ng} | \mathbf{Y}_n) = \frac{\pi_g f(\mathbf{Y}_n | \mathbf{M}_g, \boldsymbol{\Phi}_g, \boldsymbol{\Omega}_g)}{\sum_{h=1}^G \pi_h f(\mathbf{Y}_n | \mathbf{M}_h, \boldsymbol{\Phi}_h, \boldsymbol{\Omega}_h)} \rightarrow \hat{Z}^{(t+1)}_{ng} \stackrel{\text{def}}{=} \frac{\pi_g \exp[F(q_{ng}, \mathbf{Y}_n)]}{\sum_{h=1}^G \pi_h \exp[F(q_{nh}, \mathbf{Y}_n)]}$$

Poiché la distribuzione marginale di $\mathbf{Y}$ è difficile da calcolare, la sostituiamo con l'esponente dell'ELBO.

Aggiorniamo i parametri variazionali:

- $\Delta_{ng}^{t+1}, \kappa_{ng}^{t+1}$ utilizza un metodo a **punto fisso**: risolve l'equazione iterando il parametro, è semplice e non richiede derivate, ma ha una convergenza lenta (lineare) e dipende dalla contrattività della funzione.
- ξ_{ng}^{t+1} utilizza il metodo di **Newton**: converge rapidamente (quadratica) ma richiede il calcolo di derivate ed è sensibile al punto iniziale.

2. M-STEP


$$\diamond \pi_g^{(t+1)} = \frac{n_g^{(t+1)}}{N} \quad \text{con } n_g^{(t+1)} = \sum_{n=1}^N \hat{z}_{ng}^{(t+1)}$$

$$\diamond \mathbf{M}_g^{(t+1)} = \frac{\sum_{n=1}^N \hat{z}_{ng}^{(t+1)} \xi_{ng}^{(t+1)}}{n_g^{(t+1)}}$$

$$\diamond \Phi_g^{(t+1)} = \frac{\sum_{n=1}^N \hat{z}_{ng}^{(t+1)} (\xi_{ng}^{(t+1)} - \mathbf{M}_g^{(t+1)}) \mathbf{\Omega}_g^{-1(t)} (\xi_{ng}^{(t+1)} - \mathbf{M}_g^{(t+1)})^T + \sum_{n=1}^N \hat{z}_{ng}^{(t+1)} \Delta_{ng}^{(t+1)} \text{tr}\{\mathbf{\Omega}_g^{-1(t)} \mathbf{\kappa}_{ng}^{(t+1)}\}}{pn_g^{(t+1)}}$$

$$\diamond \mathbf{\Omega}_g^{(t+1)} = \frac{\sum_{n=1}^N \hat{z}_{ng}^{(t+1)} \mathbf{\kappa}_{ng}^{(t+1)} \text{tr}\{\Phi_g^{-1(t+1)} \Delta_{ng}^{(t+1)}\} + \sum_{n=1}^N \hat{z}_{ng}^{(t+1)} (\xi_{ng}^{(t+1)} - \mathbf{M}_g^{(t+1)}) \Phi_g^{-1(t)} (\xi_{ng}^{(t+1)} - \mathbf{M}_g^{(t+1)})^T}{rn_g^{(t+1)}}$$

❖ APPROCCIO IBRIDO



CONFRONTO TRA GLI APPROCCI

	MCMC-EM	VGA	IBRIDO
Genera campioni dalla distribuzione a posteriori esatta	✓	✗	✓
E' efficiente computazionalmente	✗	✓	✓

Conclusione

se l'obiettivo è:

- ❖ *determinare i cluster* ⇒ si sceglie l'approccio **VGA** (come nell'analisi di dati reali)
- ❖ *inferenza sulla posterior* ⇒ si sceglie l'approccio **IBRIDO**, che gode dei benefici di entrambi gli approcci

IDENTIFICABILITÀ

Un modello statistico $\mathbb{P} = \{ P(\theta) : \theta \in \Theta \}$ si dice **identificabile** se la mappa $\theta \rightarrow P(\theta)$ è invertibile.

In pratica, è possibile conoscere il vero parametro del modello se quest'ultimo è osservabile per un tempo indefinitamente lungo. L'identificabilità è necessaria per ottenere stimatori **consistenti** e stime **uniche**.

Il modello di mistura MVPLN, le stime di Φ_g e Ω_g sono **uniche a meno di una costante moltiplicativa strettamente positiva**. Per ovviare si introduce uno tra i seguenti vincoli:

❖ $\text{tr}(\Omega_g) = p$

❖ $\text{tr}(\Phi_g) = r$

❖ $\Phi_{g, (1,1)} = 1$

→ usata nel pacchetto mixMVPLN

MODEL SELECTION

Tra i criteri per la selezione del modello sono annoverati:

- ❖ $AIC = -2 \log \{ L(\boldsymbol{\vartheta}^{(MLE)} | \mathbf{y}) \} + 2K$
- ❖ $BIC = -2 \log \{ L(\boldsymbol{\vartheta}^{(MLE)} | \mathbf{y}) \} + K \log N$
- ❖ $AIC3 = -2 \log \{ L(\boldsymbol{\vartheta}^{(MLE)} | \mathbf{y}) \} + 3K$
- ❖ $ICL \approx BIC + 2 \sum_{n=1}^N \sum_{g=1}^G \hat{z}_{ng} \log(w_{ig})$

Qualora le vere classi siano note ma per obiettivi di valutazione ignorate, si può poi considerare:

- ❖ Adjusted Rand Index



Presenta le seguenti caratteristiche:

- è pari ad 1 se la classificazione ottenuta rispecchia perfettamente quella vera
- sotto l'ipotesi di classificazione casuale ha valore atteso nullo
- può assumere valori negativi (a differenza del Rand Index)



SIMULAZIONE



SETTING DELLE SIMULAZIONI

Simulazione 1 Un componente 1000 osservazioni 2 tempi x 3 variabili	Simulazione 2 due componenti, $\pi = (0.79, 0.21)$, 1000 osservazioni 2 tempi x 3 variabili	Simulazione 3 due componenti $\pi = (0.60, 0.40)$, 1000 osservazioni 2 tempi x 3 variabili strutture di covarianza diagonali
Simulazione 4 mistura di sei distribuzioni di Poisson indipendenti con due componenti $\pi = (0.45, 0.55)$, 1000 osservazioni	Simulazione 5 mistura di sei distribuzioni binomiali negative indipendenti con due componenti, $\pi = (0.79, 0.21)$, 2000 osservazioni	Simulazione 6 mistura di distribuzioni MVPLN con otto componenti $\pi_1 = \dots = \pi_8 = 0.125$ 1500 osservazioni 2 tempi x 3 variabili

RISULTATI DELLA SIMULAZIONE

Method	Simulation setting	Mean of normalized separation index (SD)	BIC	ICL	AIC	AIC3
Mix. of MVPLN (VGA-based approach)	1	–	1 (1.00, 0.00)	1 (1.00, 0.00)	1, 2 (0.88, 0.33)	1 (1.00, 0.00)
	2	0.44 (0.02)	2 (1.00, 0.00)	2 (1.00, 0.00)	2, 3, 4, 5 (0.89, 0.22)	2 (1.00, 0.00)
	3	0.37 (0.02)	2 (1.00, 0.00)	2 (1.00, 0.00)	2, 3, 4, 5 (0.86, 0.21)	2, 3, 4 (0.96, 0.12)
	4	0.69 (0.01)	2 (1.00, 0.00)	2 (1.00, 0.00)	2 (1.00, 0.00)	2 (1.00, 0.00)
	5	0.44 (0.02)	2 (1.00, 0.00)	2 (1.00, 0.00)	2, 5 (0.99, 0.06)	2 (1.00, 0.00)
	6	0.14 (0.01)	8 (0.99, 0.00)	8 (0.99, 0.00)	8, 9, 10 (0.99, 0.01)	8, 9 (0.99, 0.01)
HTScluster	1	–	5 (0.00, 0.00)	5 (0.00, 0.00)	5 (0.00, 0.00)	5 (0.00, 0.00)
	2	0.44 (0.02)	5 (–0.00, 0.00)	5 (–0.00, 0.00)	5 (–0.00, 0.00)	5 (–0.00, 0.00)
	3	0.37 (0.02)	5 (0.00, 0.01)	5 (0.00, 0.01)	5 (0.00, 0.01)	5 (0.00, 0.01)
	4	0.69 (0.01)	2 (1.00, 0.00)	2 (1.00, 0.00)	2, 3, 4 (0.97, 0.06)	2, 3, 4 (0.97, 0.06)
	5	0.44 (0.02)	5 (0.22, 0.01)	5 (0.22, 0.01)	5 (0.22, 0.01)	5 (0.22, 0.01)
	6	0.14 (0.01)	10 (0.03, 0.13)	10 (0.03, 0.13)	10 (0.03, 0.13)	10 (0.03, 0.13)
Fuzzy-version of <i>k</i> -means	1	–	5 (0.00, 0.00)	4,5 (0.00, 0.00)	5 (0.00, 0.00)	5 (0.00, 0.00)
	2	0.44 (0.02)	5 (0.24, 0.01)	5 (0.24, 0.01)	5 (0.24, 0.01)	5 (0.24, 0.01)
	3	0.37 (0.02)	3, 4, 5 (0.55, 0.06)	2, 3, 4, 5 (0.81, 0.23)	4, 5 (0.54, 0.04)	4, 5 (0.54, 0.04)
	4	0.69 (0.01)	2 (1.00, 0.00)	2 (1.00, 0.00)	2, 4, 5 (0.54, 0.12)	2, 4, 5 (0.54, 0.12)
	5	0.44 (0.02)	2 (1.00, 0.00)	2 (1.00, 0.00)	2, 3, 4, 5 (0.82, 0.27)	2, 3, 4, 5 (0.82, 0.27)
	6	0.14 (0.01)	8, 9, 10 (0.93, 0.03)	8, 9, 10 (0.96, 0.02)	10 (0.90, 0.01)	10 (0.90, 0.01)




CRITICITÀ DEL PACCHETTO MIXMVLPN


❖ PRIMO CASO DI STUDIO

IL **LIEVITO A FISSIONE**, O *SCHIZOSACCHAROMYCES POMBE*, È UN TIPO DI LIEVITO UNICELLULARE EUCARIOTICO, COSÌ DEFINITO POICHÈ SFRUTTA UN PROCESSO NOTO COME **FISSIONE BINARIA** PER RIPRODURSI.

LO STUDIO SI CONCENTRA SULL'ANALISI DEGLI RNA NON CODIFICANTI E SE NE STUDIA IL COMPORTAMENTO PER DUE TIPOLOGIE DI LIEVITO: UNA STANDARD E UNA MUTANTE.



Disponiamo dei dati di **counts dell'RNA-sequencing** raccolti per i lieviti e analizzati in una **serie temporale di 5 punti** (i tempi sono stati considerati a seguito della somministrazione di reagenti chimici):



- ❖ Applichiamo gli algoritmi di clusterizzazione proposti sui **geni** sfruttando le informazioni provenienti dai tempi e dalle variabili
- ❖ L'obiettivo principale è identificare dei pattern, ovvero dei geni che si esprimono in maniera concorde nei lieviti standard e del lievito mutante

CRITICITÀ

- ❖ Dopo varie iterazioni l'algoritmo si interrompe a causa della presenza di **matrici singolari**

❖ SECONDO CASO DI STUDIO

Lo studio si concentra sull'analisi trascrittomica nei nuclei autonomi del tronco encefalico di due tipologie di ratti



Spontaneously Hypertensive Rat (SHR)

Modello animale ampiamente utilizzato per studiare l'ipertensione



Wistar-Kyoto Rat (WKY)

Rappresenta il modello normoteso di controllo


Tre **nuclei autonomi** del tronco encefalico sono fondamentali per l'ipertensione neurogena

1. Nucleo del Tratto Solitario (NTS)

2. Medulla Ventrolaterale Caudale (CVLM)

3. Medulla Ventrolaterale Rostrale (RVLM)

Disponiamo dei dati di **counts dell'RNA-sequencing** raccolti per i tre nuclei autonomi del tronco encefalico (**NTS, CVLM e RVLM**) analizzati in una **serie temporale di 5 punti**



- ❖ Applichiamo gli algoritmi di clusterizzazione proposti sui **geni** sfruttando le informazioni provenienti dai tempi e dalle 3 variabili
- ❖ L'obiettivo principale è comprendere come la regolazione genica differisca tra i ratti ipertesi e normotesi

Studio di riferimento: Moss A, Kuttippurathu L, Srivastava A, Schwaber JS, Vadigepalli R. Dynamic dysregulation of transcriptomic networks in brainstem autonomic nuclei during hypertension development in the female spontaneously hypertensive rat. *Physiol Genomics*. 2024;56: 283–300. doi: 10.1152/physiolgenomics.00073.2023

CRITICITÀ

- ❖ L'algoritmo non arriva a convergenza se il numero di cluster è **superiore a 2**
- ❖ Per un numero di geni superiore a 200, dopo varie iterazioni l'algoritmo si interrompe a causa della presenza di **matrici singolari**

❖ TERZO CASO DI STUDIO

Lo studio si concentra sull'analisi trascrittomica del tessuto polmonare di due tipologie di cavie esposte dalla nascita al fumo di sigaretta



B-cell Deficient Mice (μ MT)

Cavie private dei linfociti B, addetti alla risposta immunitaria




Wild Type Mice (WT)

Cavie normotipo

Si studia il decorso della patologia da esso causato: la **broncopneumopatia cronica ostruttiva (BPCO)**.

La patogenesi della BPCO è avviata e perpetuata da una risposta infiammatoria anomala indotta dal fumo nei polmoni, che coinvolge sia l'immunità innata che quella adattativa. In particolare, le cellule B, che producono gli anticorpi addetti a reagire agli antigeni, si accumulano nei polmoni, contribuendo all'enfisema indotto dal fumo.

Disponiamo dei dati di **microarray** normalizzati per essere studiati come se rilevati tramite RNA-seq e analizzati in una **serie temporale di 2 punti**:




- ❖ Applichiamo gli algoritmi di clusterizzazione proposti sui **geni** sfruttando le informazioni provenienti dai tempi e dalle variabili
- ❖ L'obiettivo principale è comprendere come la risposta infiammatoria differisca nelle due tipologie di cavie.


CRITICITÀ

- ❖ L'algoritmo sembra funzionare. Tuttavia i dati non sono stati rilevati tramite metodologia RNA-seq, ma tramite **microarray**. I risultati sono stati poi **normalizzati** tramite un metodo non specificato, al fine di essere letti come dati di conteggio.

RIEPILOGO

Sebbene l'intuizione sia fortemente innovativa e supportata da un'adeguata formalizzazione matematica, l'algoritmo non sembra funzionare bene per motivi di varia natura. Si inserisce per questo tra i possibili obiettivi di ricerca futura.





GRAZIE PER L'ATTENZIONE

DELIA ANAMARIA BOGDAN, MARIA LAURA FAZIO, SAMUELE CONFALONE